Сценарий за презентацията

GeForce GTX 780 срещу Radeon RX Vega 56 · Системно програмиране

Обща продължителност: около 10 минути при спокойно темпо. Същият текст е в бележките към слайдовете и се вижда в Presenter View (Alt+F5 в PowerPoint).

Съвет: не чети дословно. Гледай текста само за числата и поредността, а останалото го разказвай със свои думи.

1. Корица ~0:30

Добър ден. Казвам се Константин Ганев и ще ви представя сравнение между две графични карти: GeForce GTX 780 на NVIDIA и Radeon RX Vega 56 на AMD. Между тях има четири години разлика. Точно затова сравнението е интересно: можем да видим какво се променя за едно поколение в архитектурата, паметта и енергийната ефективност и колко от това се усеща в реалната производителност.

2. Две карти, четири години разлика ~0:50

Първо накратко за двете карти. GTX 780 излиза през май 2013 г. и тогава е втората най-силна карта на NVIDIA след GTX Titan. Струва 649 долара. Vega 56 излиза през август 2017 г. като по-достъпната версия на Vega 64, на цена 399 долара, и е насочена срещу GTX 1070.

Има една интересна прилика: и двете са „орязани“ версии на най-големия чип на производителя си. GTX 780 използва чипа GK110 с част от блоковете изключени, а Vega 56 използва чипа Vega 10, пак с изключени блокове. Така на практика сравняваме и двата флагмански чипа.

3. По какво ги сравняваме ~0:30

Критериите ги избрах сам и ги подредих от вътрешността на чипа навън. Започвам с архитектурата и технологичния процес, минавам през изчислителните ресурси, паметта и консумацията, после програмния модел, а накрая реалните тестове, цената и поддръжката. Така всеки следващ извод стъпва на предишния.

4. Архитектура ~0:55

(посочи зелените и червените квадратчета)

Да започнем с устройството на чипа. При Kepler основният блок се казва SMX и съдържа 192 CUDA ядра. Пълният GK110 има 15 такива блока, а в GTX 780 работят 12. Виждате ги в зелено, а празните квадратчета са изключените. Дванадесет по 192 прави 2304 ядра.

При Vega блокът се казва NCU и има 64 поточни процесора. От 64 блока във Vega 56 работят 56, оттам идва и името. Това прави 3584 процесора.

Вижда се и разликата във философията: NVIDIA има малко, но големи блокове, а AMD много малки. За програмиста има още една разлика. NVIDIA изпълнява нишките на групи по 32, наречени warp, а AMD на групи по 64, наречени wavefront. Ще се върна към това при програмния модел.

5. Технологичен процес ~0:45

Тук е най-голямата технологична разлика. GTX 780 е произведена по 28-нанометров планарен процес на TSMC, а Vega по 14-нанометров FinFET процес на GlobalFoundries. При FinFET каналът на транзистора е триизмерен и затворът го обхваща от три страни, затова утечките са по-малки.

Резултатът е, че Vega 10 има 12,5 милиарда транзистора на по-малка площ, отколкото GK110 със своите 7 милиарда. Плътността е почти точно двойна. Снимките горе са истински снимки на кристалите, в приблизително реален мащаб един спрямо друг.

6. Изчислителни ресурси ~0:45

(посочи формулата долу вляво)

Теоретичната мощ се смята лесно: брой единици по 2 по честотата. Двойката идва от инструкцията FMA, която прави умножение и събиране наведнъж и се брои за две операции. За GTX 780 това са 4,15 терафлопса, за Vega 56 са 10,5. Тоест на хартия Vega е два и половина пъти по-мощна.

Предимството идва от две места: 55% повече единици и много по-висока честота, 1471 срещу 900 мегахерца. Освен това Vega смята с половинна точност два пъти по-бързо, а Kepler няма такова ускорение.

7. Видеопамет ~0:45

(посочи чиповете около процесора и двата стека HBM2)

Паметта е може би най-интересната разлика. Вляво е платката на GTX 780: в средата е графичният процесор, а около него 12 чипа GDDR5 с обща 384-битова шина. Вдясно е Vega 10: двата правоъгълника отдолу са стековете HBM2, поставени непосредствено до чипа върху силициев интерпозер. Шината тук е 2048 бита.

HBM2 работи почти четири пъти по-бавно на извод, но шината е пет пъти по-широка, затова в крайна сметка пренася с 42% повече данни в секунда. А днес още по-важен е обемът: 3 гигабайта срещу 8.

8. Енергия ~0:35

GTX 780 е обявена с 250 вата, а Vega 56 с 210. Тук има уговорка: двете фирми не мерят по един и същ начин, AMD дава консумацията на цялата платка. Но дори ориентировъчно разликата е ясна. Vega дава около три пъти повече изчисления на ват на теория и около 1,9 пъти в реален тест. Това е пряк ефект от прехода към 14 нанометра.

9. API и програмен модел ~0:55

(посочи кода вдясно)

За нашата дисциплина това е може би най-важният слайд. И двете карти работят с DirectX 12, но GTX 780 е на ниво 11_0, тоест без част от новите възможности, а Vega е на 12_1. Vega има и хардуерни блокове за асинхронни изчисления, така че графика и изчисления могат да вървят едновременно. Kepler не може да прави това ефективно.

За изчисления с общо предназначение GTX 780 използва CUDA, но Kepler е премахнат от CUDA 12 през 2022 г., така че за нея остава CUDA 11. Vega се програмира с OpenCL или с HIP.

Вдясно е стартирането на едно и също ядро в двата модела и виждате, че е почти еднакво. Разликата е в размера на групата: при NVIDIA блокът е добре да е кратен на 32, при AMD на 64. Блок от 256 нишки е удобен и за двете.

10. Тестове ~0:35

Сега реалните тестове. В PassMark има резултати от хиляди реални компютри, около 9000 за GTX 780 и почти 4000 за Vega. Там Vega 56 е с 62% по-бърза. В 3DMark Time Spy, който е тест за DirectX 12, разликата е почти два и половина пъти. Тоест реалното предимство е по-малко от теоретичното и зависи много от теста.

11. Разликата зависи от API-то ~0:45

(посочи двойката стълбове при DirectX 11)

Тук се вижда защо. PassMark има отделни сцени за различните версии на DirectX. При DirectX 11 разликата е само 26%. Това е API-то, за което е проектиран Kepler, и драйверите на NVIDIA за него са много добре оптимизирани. При DirectX 12 Vega вече е с 87% по-бърза.

Интересно е и долното каре вдясно. Ако разделим точките на теоретичните терафлопси, GTX 780 изкарва повече от всеки терафлопс. Значи Kepler използва мощта си по-пълно, а GCN разгръща потенциала си главно при DirectX 12, Vulkan и изчисления.

12. Цена ~0:30

GTX 780 излиза на 649 долара и пет месеца по-късно, след като AMD пуска R9 290X, поевтинява до 499. Vega 56 излиза на 399. Ако разделим точките в PassMark на цената, Vega дава 2,6 пъти повече за всеки долар. Уговорката е, че през 2017 и 2018 г. реалните цени на Vega бяха по-високи заради копачите на криптовалути.

13. Поддръжка ~0:35

А как стоят нещата днес? За GTX 780 NVIDIA спира новите драйвери през 2021 г., през 2022 г. Kepler отпада от CUDA, а от септември 2024 г. няма и поправки за сигурност. Vega следва същия път с няколко години закъснение: през 2023 г. минава на отделен клон драйвери без оптимизации, а през май 2026 г. официално става legacy. И двете карти са в края на жизнения си цикъл, но Vega все още получава поправки.

14. Обобщение ~0:25

Ако обобщим по показателите, Vega 56 печели в осем от девет. GTX 780 има предимство само в едно: по-пълното използване на мощта си в по-старите API. Това обаче не компенсира два и половина пъти по-ниската изчислителна мощ и почти три пъти по-малката памет.

15. Изводи ~0:40

Накратко, четири извода. Първо, технологичният процес решава: от него идват плътността, честотата и ефективността. Второ, теорията не е практика: два и половина пъти на хартия, между 1,3 и 2,4 пъти в тестовете. Трето, паметта остарява първа: 3 гигабайта са най-голямото ограничение на GTX 780 днес. И четвърто, днес и двете карти са история. За нова система не бих препоръчал нито една, но Vega 56 все още става за по-стари игри на 1080p и за учебни задачи с OpenCL и Vulkan.

Общият победител е Radeon RX Vega 56.

16. Благодаря ~0:10

Източниците, които използвах, са изброени вляво, а подробностите са в обяснителната записка. Благодаря за вниманието. Ако имате въпроси, ще се радвам да отговоря.

Ако те питат

1. **Какво е FinFET?**

   Транзистор, при който каналът стърчи нагоре като перка и затворът го обхваща от три страни. Така токът се контролира по-добре и утечките са по-малки, затова може по-висока честота при същата консумация.

2. **Каква е разликата между warp и wavefront?**

   И двете са група нишки, които изпълняват една и съща инструкция едновременно: 32 нишки при NVIDIA, 64 при AMD. Размерът на блока трябва да е кратен на групата, иначе остават празни места. При разклонения (if/else) по-голямата група губи повече.

3. **Защо TDP и TBP не може да се сравнят директно?**

   TDP е колко топлина трябва да отведе охлаждането на чипа. TBP е консумацията на цялата платка, заедно с паметта и захранващите вериги.

4. **Защо Vega губи част от предимството при DirectX 11?**

   Драйверите на NVIDIA за DirectX 11 са много добре оптимизирани, а GCN не успява да натовари всичките си изчислителни единици. При DirectX 12 и Vulkan натоварването се разпределя по-добре и има async compute.

5. **Какво е HBCC?**

   Контролер във Vega, който използва видеопаметта като кеш. Част от данните може да стоят в системната памет, а адресното пространство стига до 512 TB.

6. **Може ли днес да се пише CUDA код за GTX 780?**

   Да, но само с CUDA 11 и по-стар драйвер. От CUDA 12 нататък Kepler не се поддържа.

7. **Защо Vega 56 има два 8-пинови конектора при 210 W?**

   За резерв. Позволяват да се вдигне лимитът на мощността при овърклок, общо до 375 W заедно със слота.

8. **Защо снимката на кристала е от Vega 64?**

   Vega 56 и Vega 64 използват един и същ кристал, Vega 10. При Vega 56 просто са изключени 8 изчислителни единици.